腾讯云 TI-ONE 平台调研报告

一、基础功能

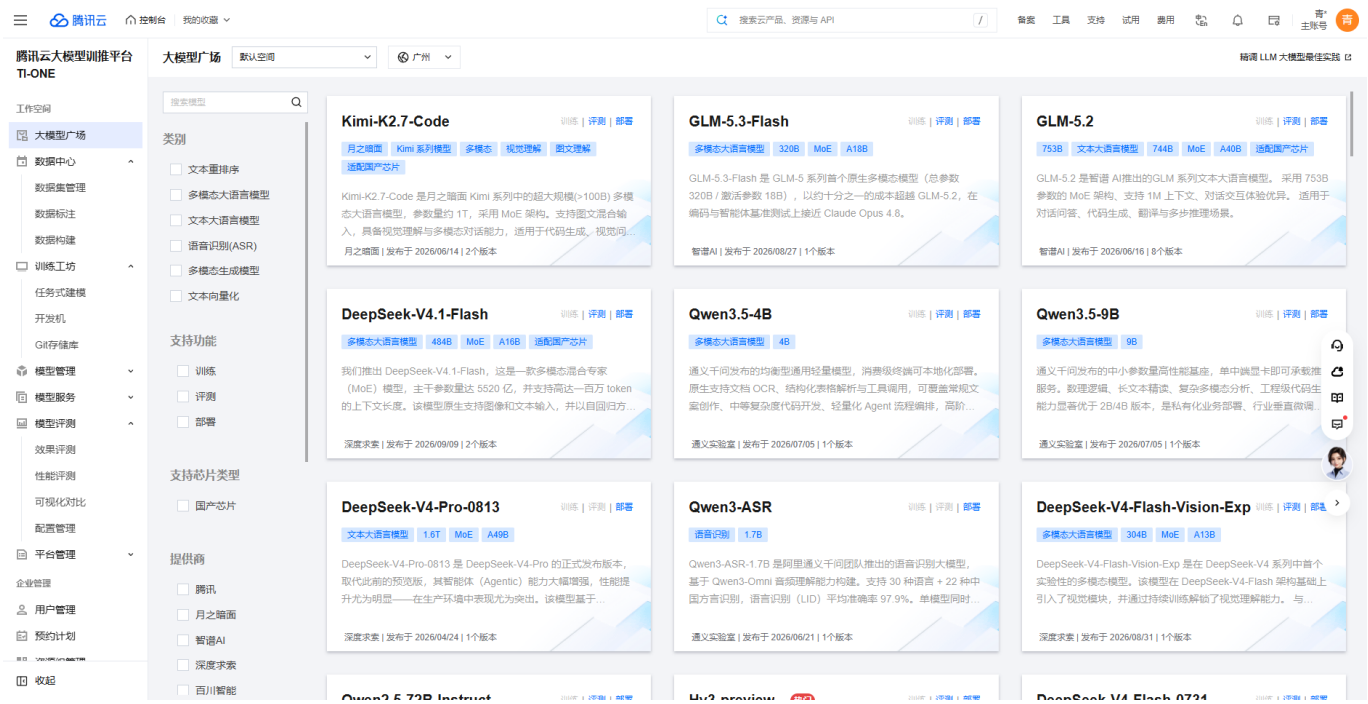


图 1　TI-ONE 大模型广场

大模型广场，这个应该是各个平台基础通用的。

二、数据集及其训练

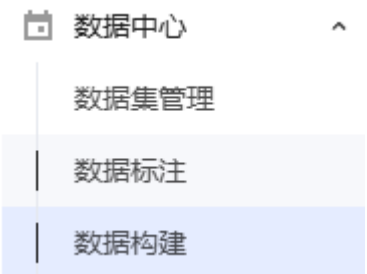


图 2　数据集管理

腾讯云基于它本身的文件系统 COS 实现了以下功能：

- 建立自己的数据集；
- 基于数据集进行数据标注和构建。

本身和腾讯云的文件系统是解耦的，是一个单独的模块。

三、模型训练



> 图 3　模型训练入口

模型训练有两种形式：

3.1 任务式训练

提前写好命令、确认镜像，开始任务后即直接按照 Shell 命令运行，并提供实时日志、SSH 连接、申请 GPU 数量等基础功能。

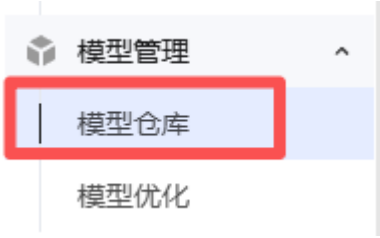
另外，腾讯云提供了 Git 功能，可以直接将 Git 中的代码传输到个人文件系统，方便训练。这个功能值得借鉴。

3.2 开发机

提供在线 IDE，可以直接与自己文件系统中的代码等文件产生交互，方便及时微调代码中的参数等。

四、模型管理

通过模型训练得到的模型，可以在模型管理模块中进行管理。



> 图 4　模型管理入口

4.1 模型仓库



图 5　模型仓库

定义好模型格式和框架后，即可将自己训练好的模型保存在模型仓库中，方便记录模型版本、训练参数等信息。

4.2 模型优化

模型优化利用 TI-ONE 优化引擎，进行无损或者 FP16 压缩。



图 6　模型优化

优化前后的模型分别存储，是两个不同的模型。

五、模型服务

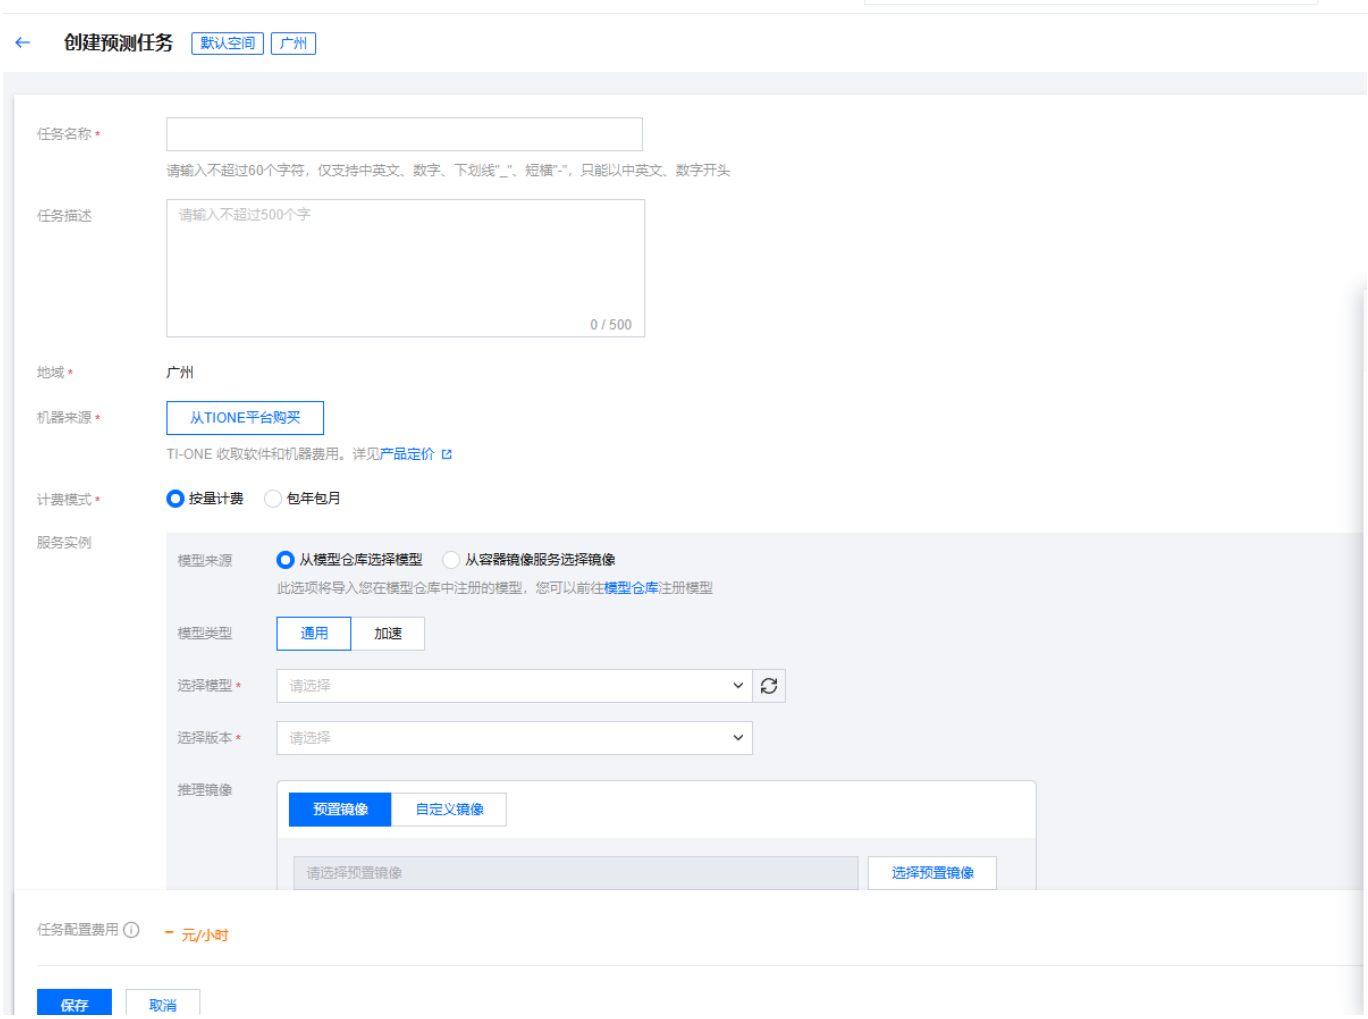


> 图 7　模型服务

模型服务算是腾讯云的一个特色。平台替用户部署已经生成好的模型；作为商业软件，模型服务可以长期运行在腾讯云上，方便上层软件直接调用 API。

- 该功能偏商务，对于我们没啥必要

5.1 批量预测



> 图 8　批量预测

使用已经训练好的模型，一次性处理大量数据，并把结果写入存储系统

六、模型评测

6.1 创建预热数据集

按照下表填写数据，创建中文本评测配置的预热数据集：

字段	说明
评测类型	选择“性能评测”
数据来源	选择“从 CFS 中选择评测集”
CFS 文件系统、评测集路径	填写中文本预热数据存储的 CFS 路径
评测集名称	可填“中文本-预热”
推理超参设置	可维持默认设置
评测指标	可不选
负责人	可选自己，也可根据实际情况选择

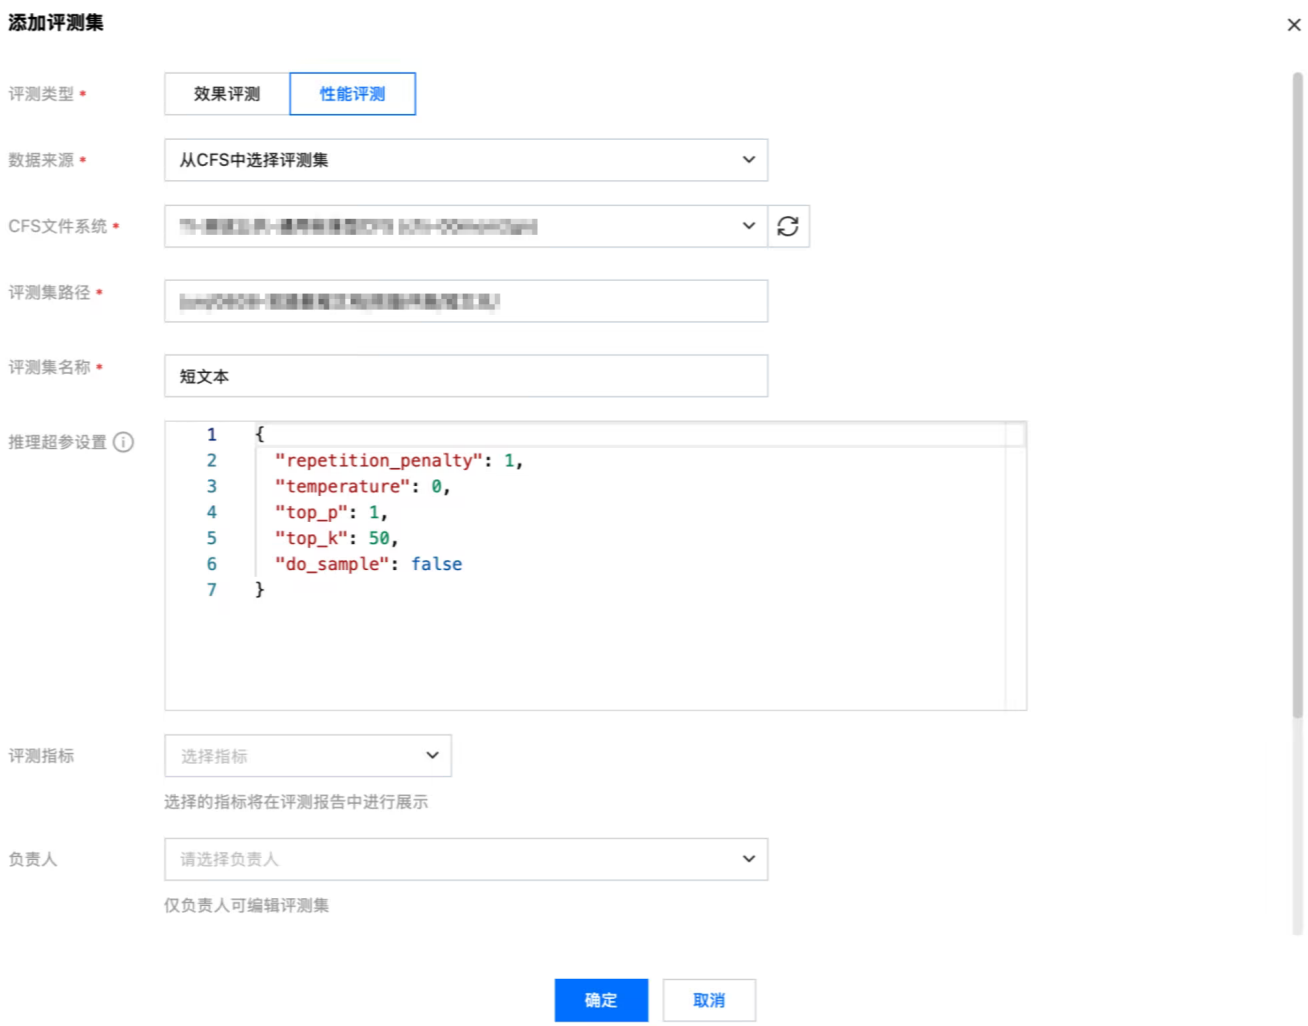


图 9　创建预热数据集

6.2 创建 Baseline

接着创建 Baseline：



图 10　创建 Baseline

字段	说明
基线标准名称	可填“Qwen3_4B-基准”
负责人	可选自己，也可根据实际情况选择
类型	选择“性能评测”
来源	选择“供应商”
供应商名称	选择“通义实验室”
模型名称	填写“Qwen3-4B”
选择评测集	选择步骤一中创建的短文本、中文本两个数据集
指标值与浮动规则	为数据集增加两个指标：Avg TTFT 设置为 0.50 s，上下浮动 5.00%；Avg TPOT 设置为 0.20 s，上下浮动 5.00%

6.3 选择测试模式

可以选择不同测试模式，例如：

- 多文本压测；
- 中文本多并发压测。

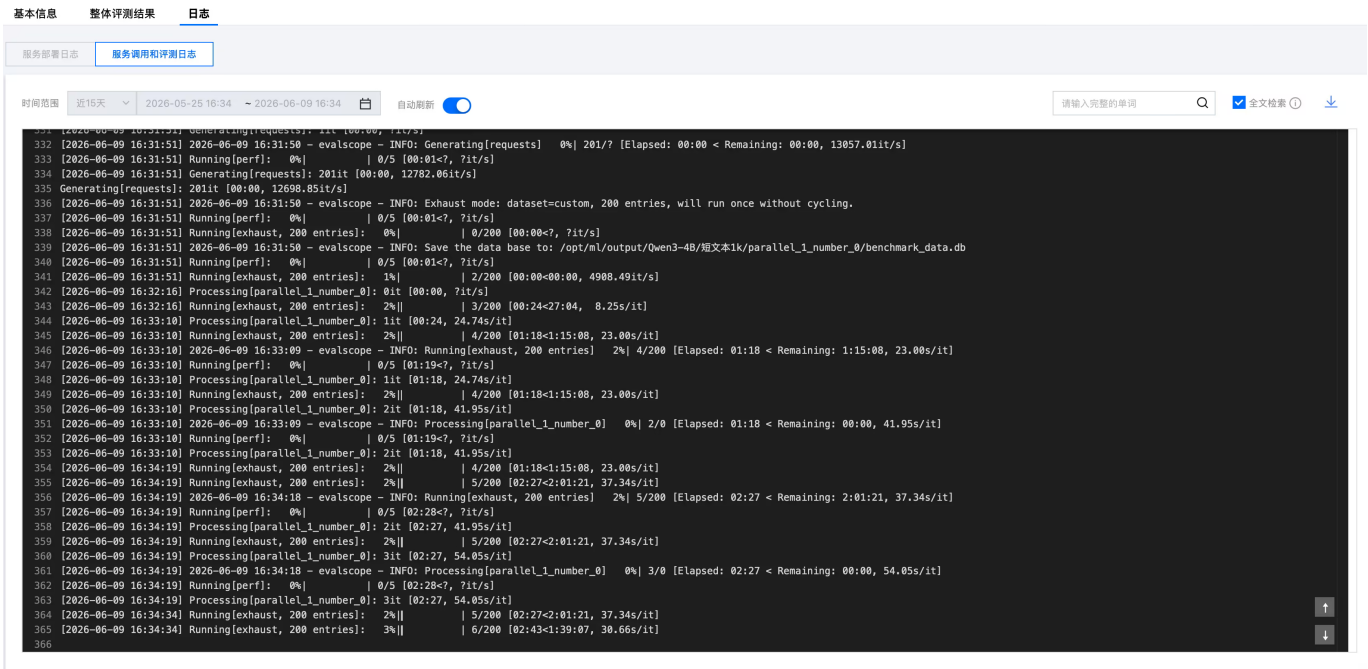


图 11　测试模式配置

6.4 查看评测结果

评测过程中可以实时查看任务日志。

任务完成后，单击 **整体评测结果**，即可查看评测结果。

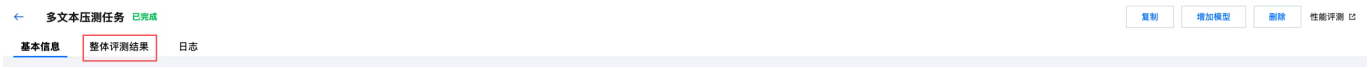


图 12　整体评测结果

查看整体评测进度，并可下载评测结果。

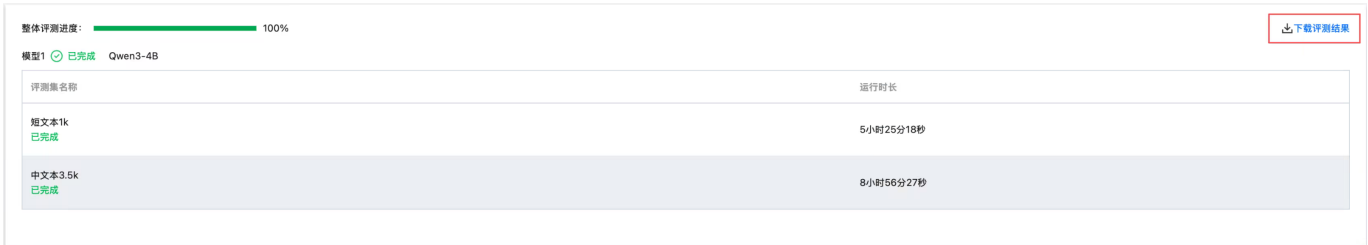


图 13　整体评测进度

待评测模型选择“Qwen3-4B”，可查看“短文本 1K”“中文本 3.5K”两个配置的基线对比报告。

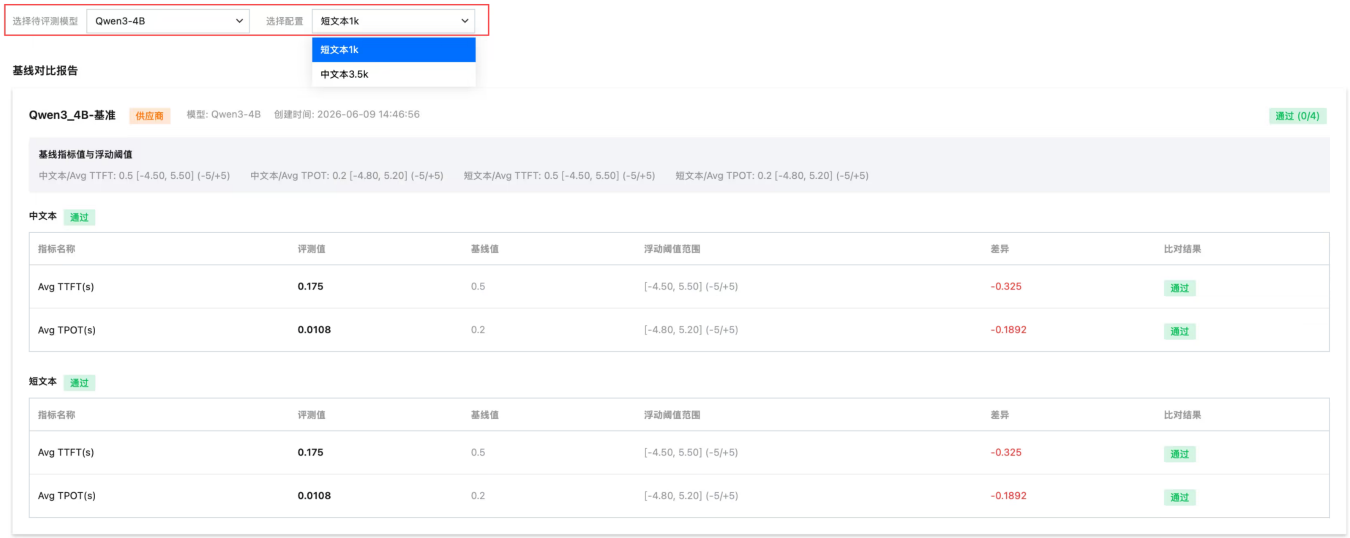


图 14　基线对比报告

查看整体指标和趋势图。鼠标悬浮在指标数值上，单击 **设置**，可以把对应数值作为最终的整体指标值。

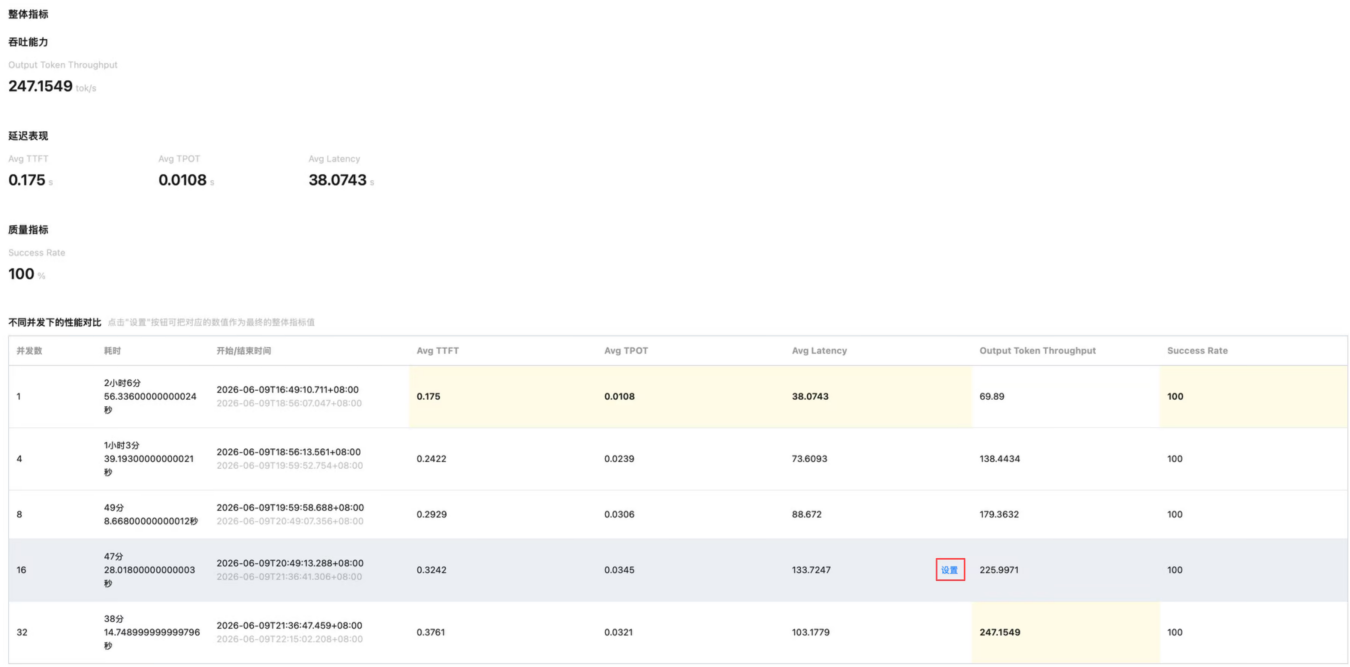


图 15　整体指标

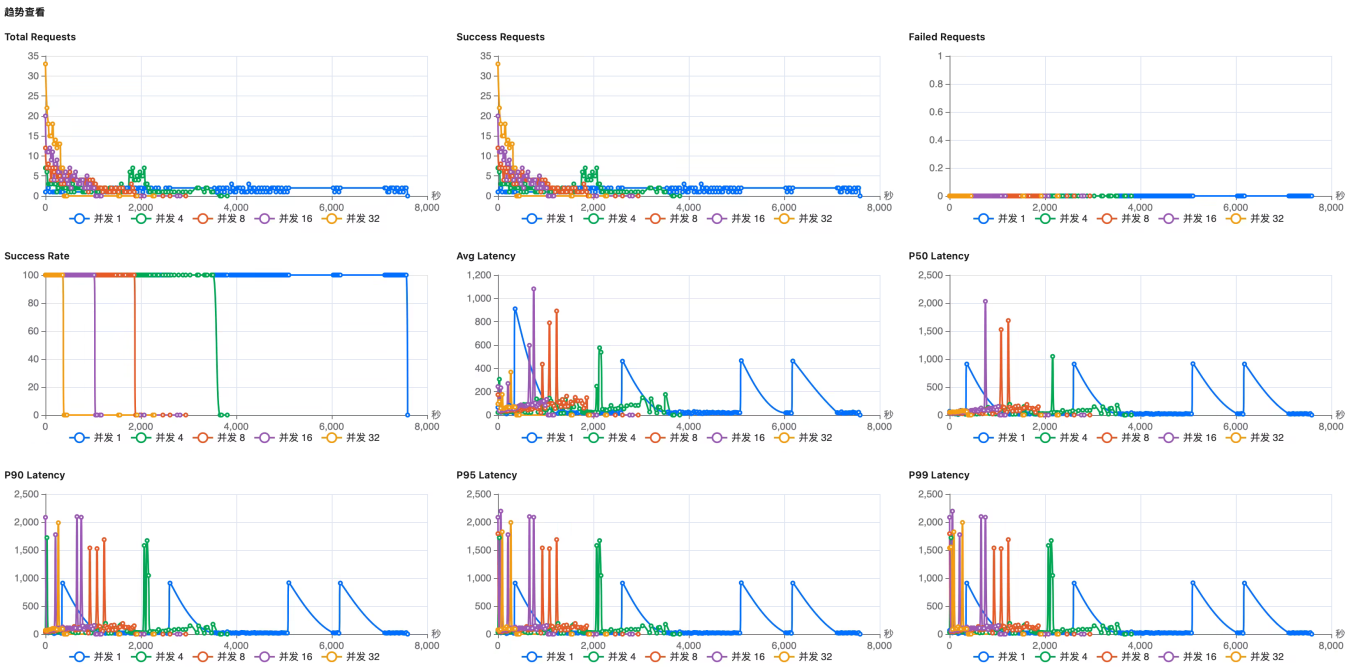


图 16　指标趋势图

6.5 多模型性能对比

查看多模型性能对比时，可以选择指标并查看性能雷达图。

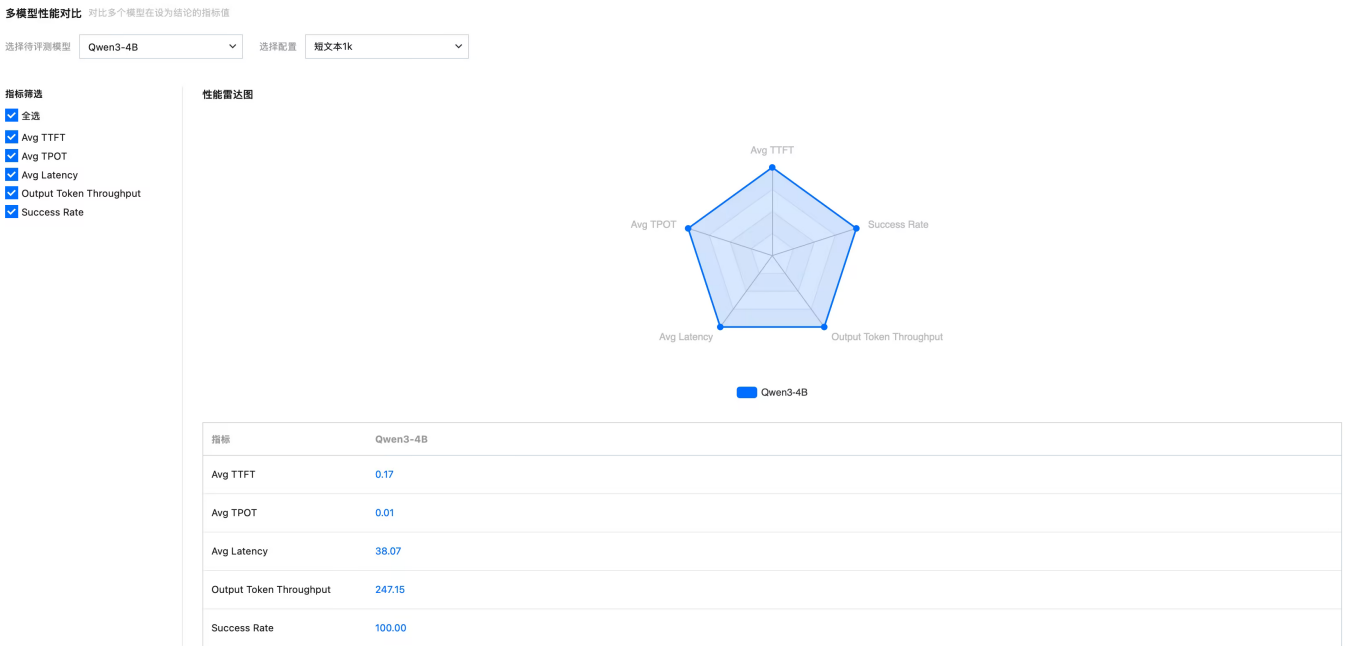
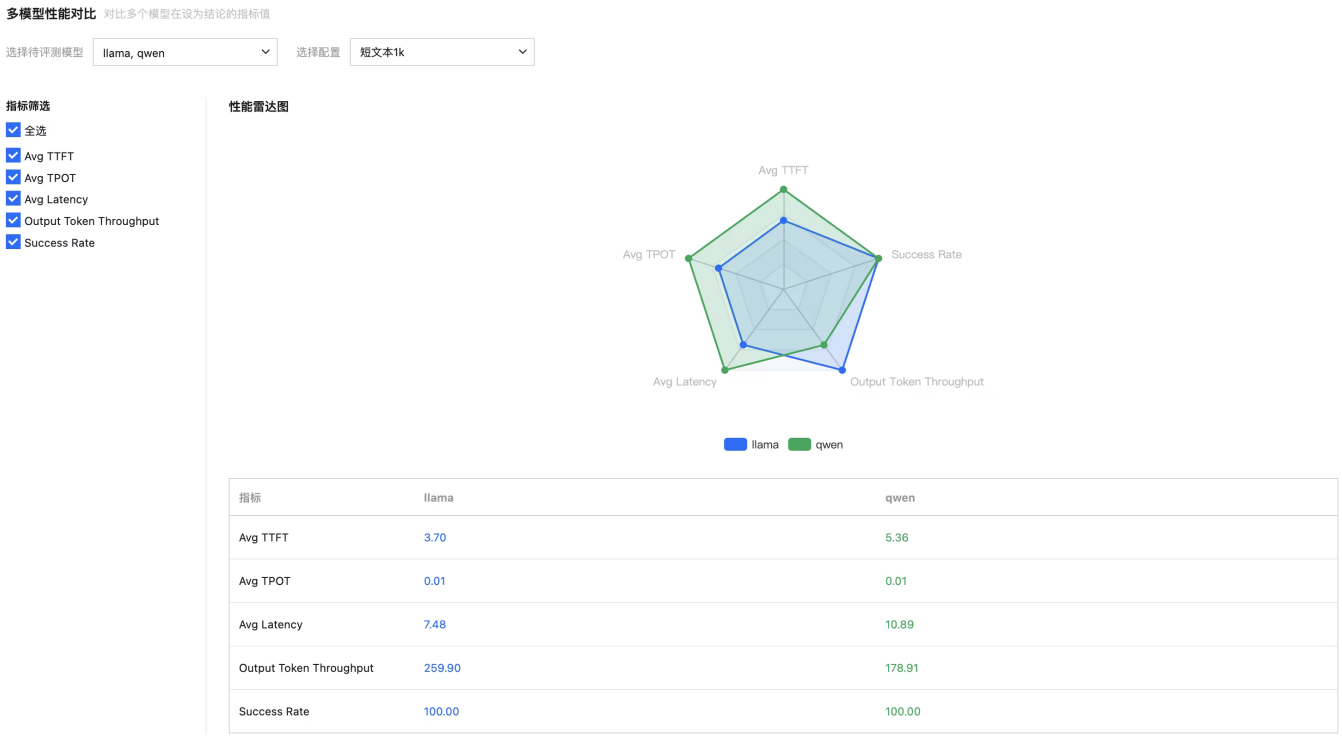


图 17　多模型性能雷达图

若想添加其他模型进行对比，可在性能评测列表中找到当前任务，单击 **增加模型**，补充评测其他模型。

多模型对比图示例如下：



指标	llama	qwen
Avg TTFT	3.70	5.36
Avg TPOT	0.01	0.01
Avg Latency	7.48	10.89
Output Token Throughput	259.90	178.91
Success Rate	100.00	100.00

图 18　多模型性能对比

最后就是一些关于企业的了，咱们肯定是用不到