阿里云 PAI 平台真实体验调研

调研日期：2026 年 9 月 28 日
调研地域：华东 2（上海）
调研对象：阿里云人工智能平台 PAI

一、功能概览与核验范围

PAI 用工作空间组织模型、数据和任务，提供从开发、训练到部署的多个入口。**页面中有某项功能，不等于本次已经验证它的运行效果。**

功能	本次核验情况	可参考的设计
Model Gallery 模型广场	实际搜索、筛选并查看模型详情	模型卡片显示来源、参数量、许可和支持的操作
数据集管理	查看列表、填写登记表单、切换文件导入，随后取消	数据集信息、权限、版本、存储路径和挂载路径分开配置
大模型训练配置	打开 Qwen3-0.6B 表单，切换验证集选项并编辑学习率，未提交	预设训练策略、默认参数和折叠高级设置
DLC 任务列表	实际进入列表并清除筛选，显示 0 条	搜索、状态字段、资源字段及批量操作入口
DSW、Designer	看到控制台入口；运行能力仅查阅文档	云端开发环境、可视化建模
日志、TensorBoard、模型产物	仅查阅文档，没有本账号运行结果	训练状态、日志和指标关联到任务
模型管理、EAS 在线服务	能力仅查阅文档，未注册或部署模型	模型版本管理、在线调试与 API 调用
工作空间、成员与资源配额	已进入默认工作空间；权限和配额能力仅查阅文档	普通用户与管理员分工、资源使用限制

文档介绍参考：PAI 新用户指引、工作空间权限管理。

二、实际体验流程

```
已登录 PAI → 搜索模型 → 按训练能力筛选 → 查看模型详情
→ 打开训练配置 → 查看公共数据预览 → 设置验证集 → 编辑参数
→ 关闭未提交的训练表单 → 查看数据集登记表单并取消
→ 查看真实 DLC 任务列表（0 条）
```

1. 搜索模型，再筛选支持的操作

进入“快速开始 → Model Gallery”，搜索 `Qwen3-0.6B`，页面返回普通版、FP8 版和 Base 版共 **3 个结果**。普通版与 Base 版卡片标明“部署/训练/评测”，FP8 版标明“部署/评测”。

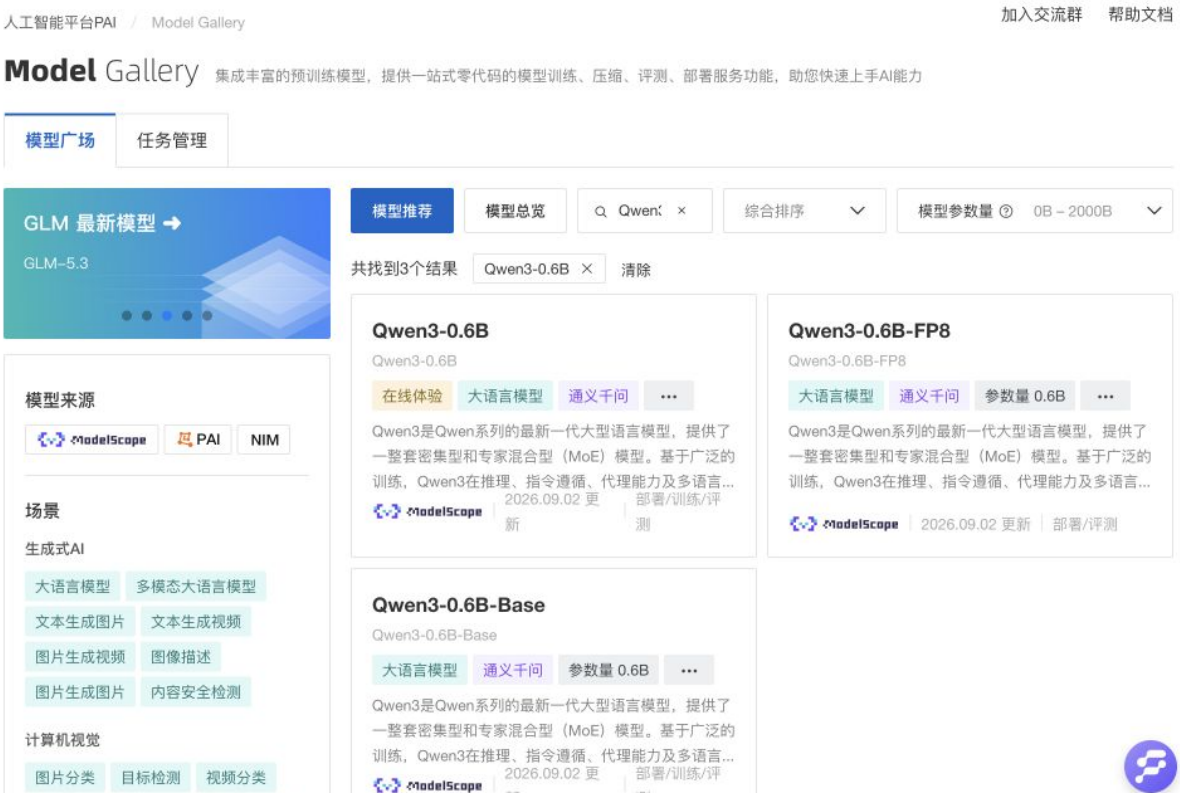


图 1：本次真实搜索结果，包含 3 个版本。

再点击“支持操作”中的“训练”，页面显示 **2 个结果**，FP8 版被排除。这说明模型目录能按可执行操作筛选，不能仅凭模型名称或系列判断训练能力。

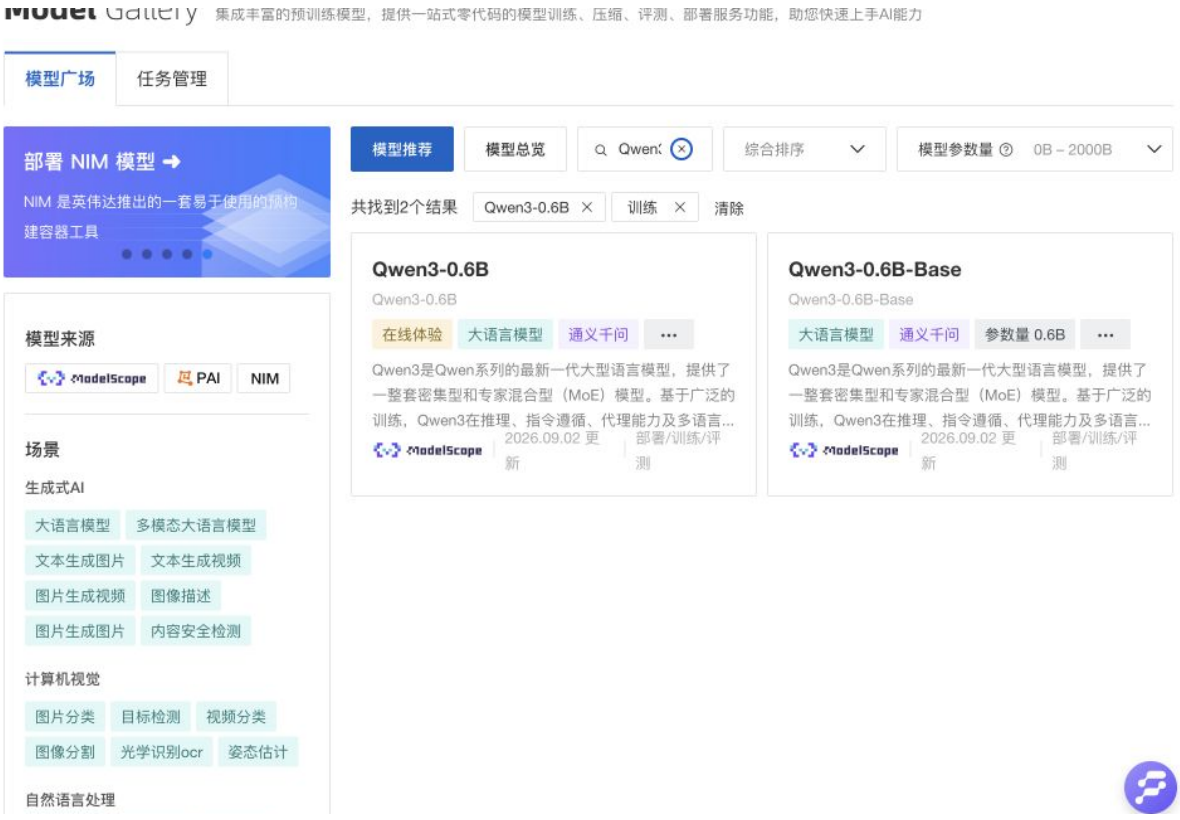


图 2：本次真实筛选后，结果为普通版与 Base 版。

2. 查看模型详情

打开普通版 `Qwen3-0.6B`，详情页有“部署”“训练”“评测”按钮，模型卡片显示参数量 `0.6B`、模型大小 `1.4 GB` 和 `Apache-2.0` 许可，并提供模型介绍、部署说明和数据格式说明。以上是页面信息，本次未下载模型或测试模型效果。



图 3：本次真实模型详情。模型信息和可执行操作放在同一页面。

3. 打开训练配置

点击详情页顶部“训练”打开配置窗口。默认选中 **SFT 监督微调 + LoRA**；页面还列出 GRPO、QLoRA、全参微调和面向特定硬件的选项。硬件选项旁有资源申请提示。



图 4：本次真实配置窗口。打开配置窗口没有启动训练。

表单中标星的字段包括任务名称、训练数据集、模型名称、模型输出路径及任务资源等。公共数据配置处还显示 RAM 角色选择项。本次没有完成所有任务配置，也未点击窗口底部用于提交任务的“训练”按钮。

4. 查看公共数据预览与验证集配置

训练表单自动带入公共数据集 `Chinese-medical-dialogue-data`，预览表按 `instruction` 和 `output` 两列展示样本。这里记录的是平台预置数据的真实预览，**不是本次模型生成的回答，也不代表本次对数据质量作出了验证。**



图 5：本次实际加载出的数据名称、字段和样本预览。没有上传本地文件。

验证集默认为“不配置”，另有“数据自动拆分”“添加验证数据集”。本次切换到“数据自动拆分”后，页面出现必填的拆分比例，初始值为 **5%**。



图 6：本次实际切换后出现比例输入框，验证了表单选项联动；没有执行数据拆分任务。

5. 编辑参数，核对资源与输出配置

展开“超参数”，核对输入框当前值后，将学习率从 `5e-5` 改为 `0.0001`。页面显示更新后的值，证明可以手动编辑。此次修改仅用于体验表单，未验证训练效果，也不作为推荐参数。

配置项	本次打开表单时的值	本次操作
training_strategy	sft	保留
learning_rate	5e-5	改为 0.0001
num_train_epochs	1	保留
per_device_train_batch_size	1	保留
seq_length	128	保留
lora_dim / lora_alpha	32 / 32	保留
gradient_accumulation_steps	8	保留

这些默认值仅对应本次选择的模型、训练方式和页面版本。

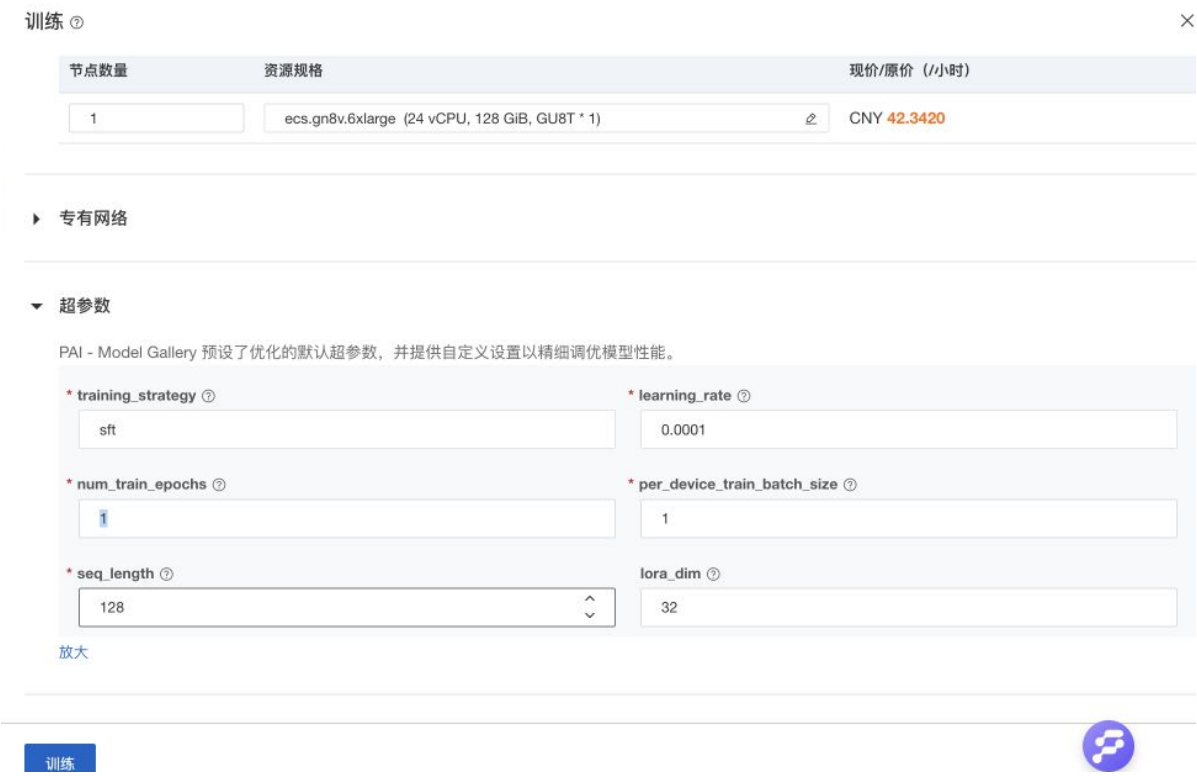


图 7：本次填写后的学习率为 0.0001。资源栏显示节点数、规格和每小时价格，属于配置报价，不是实际消费记录。

表单还提供模型输出路径、TensorBoard 输出路径、实验关联及自动容错设置。最大运行时长初始为 `0` 分钟，旁边明确提示“为 0 则不会因超时中断任务，停止后不可恢复”。这些设置可以帮助用户控制任务，但本次没有验证实际超时或容错行为。查看结束后关闭表单。

6. 查看数据集登记与挂载配置

进入工作空间中的“AI资产管理 → 数据集 → 新建数据集”，填写名称 `pai-free-research`，仅体验输入。页面默认选择“基础型”、对象存储 OSS 和“通用”内容类型，名称上限显示为 127 个字符。

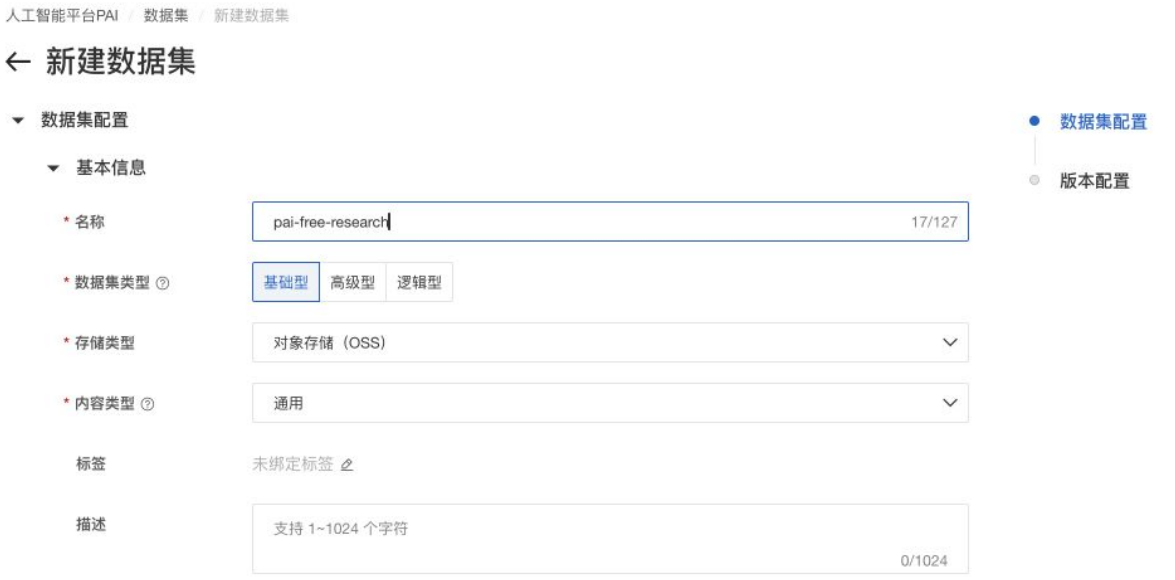


图 8：本次真实填写名称后的表单，尚未保存为数据集。

继续查看权限和版本配置：可见范围与读写权限分开设置，初始版本为 `v1`。导入格式默认“文件夹”，本次切换为“文件”；两者均需配置 OSS 路径，默认挂载路径为 `/mnt/data/`。

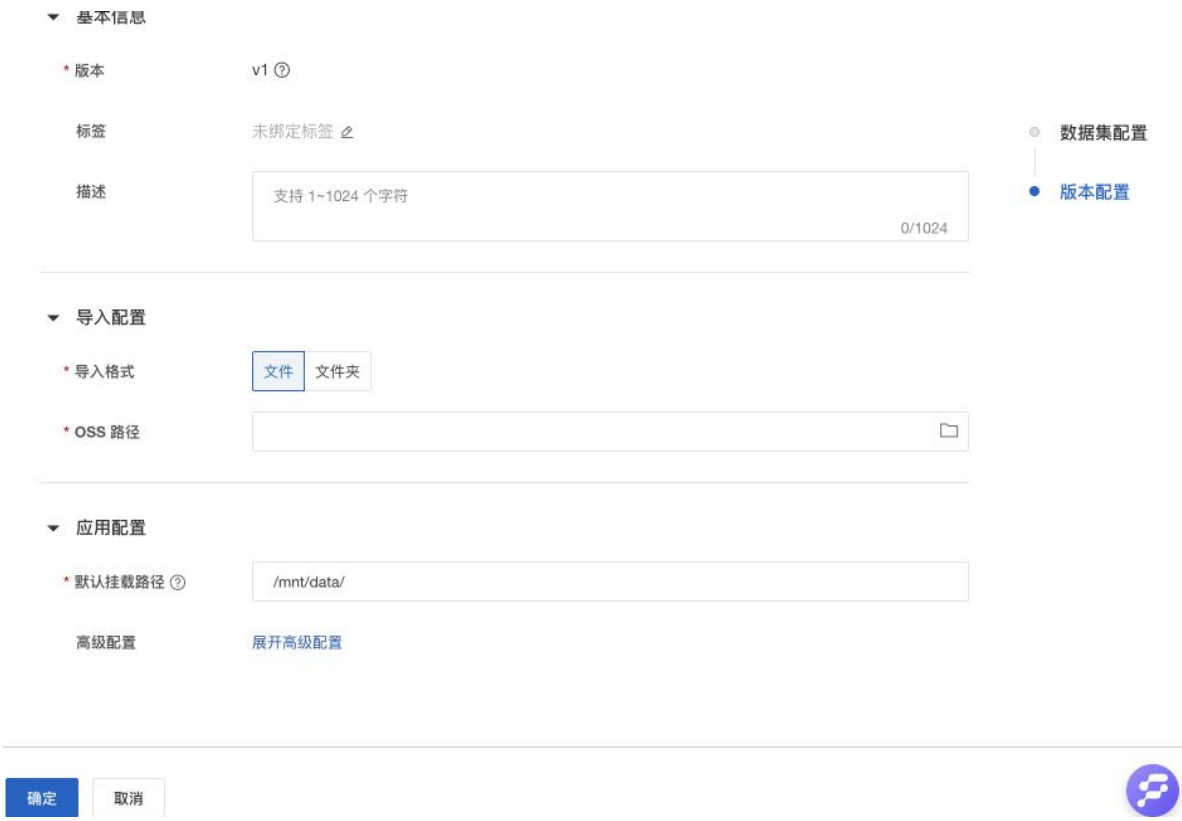


图 9：本次真实切换到文件导入后的配置，OSS 路径仍为空。随后点击“取消”，没有创建数据集或上传数据。

体验感受：数据集登记不等于文件上传。用户需要理解“云端存储地址”和“训练容器挂载路径”的区别；数据集入口也需要先进入工作空间才能看到。

7. 查看真实任务列表

进入“模型开发与训练 → 分布式训练（DLC）”。关闭“只看我的”，清除日期范围，列表仍显示“暂无数据”“共 0 条”；删除、停止、对比等按钮不可用。



图 10：本次实际空任务列表，日期筛选已清空，“只看我的”已关闭。没有使用官方演示任务填充页面。

列表包含名称、资源、框架、状态、排队及运行时间等字段，部分列需要横向查看。本次没有任务可进入详情，因此没有实际验证排队、运行日志、指标曲线或训练结果。

三、官方文档说明，未实测

以下用于补充训练至推理的后续环节，**不属于本次完成的操作**，不配演示截图：

1. 准备符合模板格式的数据和持久化输出存储，完成角色与资源配置后提交训练。
2. 在任务详情查看状态、系统事件和用户日志；训练指标需由训练代码记录，再通过 TensorBoard 等方式查看。
3. 检查模型输出文件及注册状态，保存模型版本。
4. 配置 EAS 服务，部署成功后进行在线调试或 API 调用，最后停止不再使用的服务。

依据：Model Gallery 快速入门、查看训练详情、TensorBoard 使用说明、注册及管理模型、服务在线调试。

四、从实际体验出发的创新点

这些是面向课程平台的设计建议，不代表 PAI 没有相关能力。

本次观察	我们可以做的改进	可验证的实现目标
同一模型系列的不同版本支持操作不同	按训练/部署能力筛选，说明不支持某操作的原因	不能训练的版本不进入训练选择列表
数据、角色、输出路径和资源分散在长表单中	提交前显示配置摘要与缺项清单，支持跳转定位	缺项时能找到具体字段，而不是只显示提交失败
数据预览与验证集拆分放在训练表单中	增加字段检查、空样本提示及拆分后数量预估	错误提示包含字段和样本位置；区分估算与实际拆分结果
存储路径和挂载路径容易混淆	用“数据存在哪里—训练时从哪里读取”解释路径关系	同时显示源地址、容器路径及只读/读写用途
参数有默认值，资源栏有小时价格	提供参数说明、预计费用范围及明确的运行时限	标注费用估算依据；不能把估算当作最终账单
真实空任务页没有日志或曲线可查看	区分未提交、等待、运行、失败和完成，空状态提供下一步入口	无任务时不给出虚构指标，任务创建后再展示实际数据

课程初期建议优先做 **模型/训练模板、数据集管理、配置检查、任务列表与日志、模型版本和推理测试**。多机多卡、在线开发环境、复杂企业权限可作为后续扩展。

五、简短结论与真实性边界

PAI 可借鉴的重点是：模型卡片标明可执行操作，训练表单提供默认参数与数据预览，工作空间集中组织数据和任务。初次使用的主要理解成本在于工作空间入口、权限、存储路径和资源配置。

本次完成了免费页面与配置体验，未新增授权、未绑定计费资源，也未提交训练或部署。本次没有生成训练任务、模型产物、Loss 曲线、训练耗时或推理结果；不能据此评价模型效果、GPU 调度性能或部署稳定性。